

LAPORAN TEKNIS KOMPREHENSIF

Sistem Manajemen Inventaris Cerdas Berbasis AI untuk UMKM

Smart Inventory Forecasting

Capstone Project | Data Science

Tools: Python | Google Colab | Streamlit

2024 / 2025

Judul Proyek	Sistem Manajemen Inventaris Cerdas Berbasis AI untuk UMKM
Sub Judul	Smart Inventory Forecasting
Dataset	Retail Transactions Dataset (13 Kolom, Multi-kota)
Tools	Python, Google Colab, Streamlit, Pandas, Scikit-learn, SciPy
Metode Utama	Statistical Forecasting: Rolling Mean, Lag Features, Safety Stock
A/B Testing	Independent T-Test & One-Way ANOVA (scipy.stats)
Deployment	Streamlit Cloud (akses publik)
Tahun	2024 - 2025

BAB 1 – PROBLEM DISCOVERY

1.1 Latar Belakang

Usaha Mikro, Kecil, dan Menengah (UMKM) merupakan tulang punggung perekonomian nasional. Namun mayoritas UMKM masih mengandalkan intuisi atau pencatatan manual untuk mengelola stok, sehingga rentan terhadap dua masalah utama: **overstock** (modal mengendap jadi deadstock) dan **stockout** (kehilangan penjualan akibat kehabisan stok).

1.2 Posisi Solusi: Painkiller vs Vitamin

PAINKILLER — Proyek ini bukan sekadar aplikasi pencatatan stok (vitamin). Sistem ini secara aktif mencegah kerugian finansial UMKM dengan meramalkan kebutuhan stok berbasis data historis transaksi, sehingga modal tidak mengendap menjadi deadstock dan arus kas tetap sehat.

1.3 Identifikasi Pain Point

#	Pain Point	Dampak
1	Pencatatan stok manual (intuisi/buku/Excel)	Error input, tidak real-time
2	Tidak ada sistem prediksi permintaan	Overstock / Stockout tidak terdeteksi dini
3	Modal mengendap di deadstock	Arus kas tersendat
4	Tidak ada insight berbasis data	Keputusan bisnis tidak akurat
5	Tidak ada peringatan restock otomatis	Kehilangan penjualan karena kehabisan stok

1.4 Rumusan Masalah

- Produk apa yang paling sering terjual dan menghasilkan total nilai penjualan tertinggi?
- Bagaimana tren jumlah transaksi dan total estimasi nilai belanja dari waktu ke waktu?
- Pada quarter mana penjualan produk paling tinggi dan apakah polanya konsisten setiap tahun?
- Kategori pelanggan mana yang paling banyak bertransaksi dan memiliki rata-rata nilai belanja tertinggi?
- Produk mana yang berisiko kehabisan stok dan berapa jumlah restock yang direkomendasikan?

1.5 Tujuan Proyek

- Membangun sistem peramalan stok berbasis Rolling Mean dan Lag Features dari data historis transaksi.
- Menghasilkan rekomendasi restock otomatis dengan buffer safety stock 20% per produk.
- Melakukan A/B Testing statistik (T-Test dan ANOVA) untuk memvalidasi fitur yang dibangun.
- Membangun dashboard interaktif Streamlit yang dapat diakses publik oleh pelaku UMKM.
- Menyusun laporan teknis komprehensif dari Problem Discovery hingga deployment.

BAB 2 – DATA GATHERING, ASSESSING & CLEANING

2.1 Sumber & Pengumpulan Data

Dataset berupa file CSV bernama **Retail_Transactions_Dataset.csv** yang diakses dari Google Drive menggunakan **google.colab.drive**. Data ini merepresentasikan transaksi retail multi-kota yang mencakup berbagai jenis toko dan kategori pelanggan.

```
df = pd.read_csv('/content/drive/MyDrive/Capstone/Retail_Transactions_Dataset.csv')
```

2.2 Data Dictionary

Kolom	Tipe Data	Deskripsi
Transaction_ID	String/Int	Identifikasi unik setiap transaksi
Date	Object -> DateTime	Tanggal & waktu transaksi (dikonversi ke datetime)
Customer_Name	String	Nama pelanggan
Product	String (list repr)	Daftar produk dalam 1 transaksi (di-parse & explode)
Total_Items	Integer	Jumlah total item dibeli
Total_Cost	Float	Total biaya transaksi (USD)
Payment_Method	String	Metode pembayaran: Cash, Credit Card, Debit Card, Mobile Payment
City	String	Kota transaksi (LA, Houston, Chicago, dll.)
Store_Type	String	Jenis toko: Warehouse Club, Specialty Store, Department Store, Pharmacy
Discount_Applied	Boolean	Status diskon: True/False (dikonversi ke Ya/Tidak)
Customer_Category	String	Segmen pelanggan: Homemaker, Professional, Young Adult, dll.
Season	String	Musim saat transaksi: Winter, Spring, Summer, Fall
Promotion	String/NaN	Jenis promosi: BOGO, Discount on Selected Items, atau NaN

Tabel 2.1 – Data Dictionary Retail Transactions Dataset

2.3 Assessing Data – Quality Issues

Ditemukan **7 Quality Issues (QI)** dan **3 Tidiness Issues (TI)**:

Kode	Issue	Detail Temuan
QI-1	Missing Values	Kolom Promotion memiliki nilai null (sekitar 50% baris)
QI-2	Tipe Data Tidak Sesuai	Kolom Date masih bertipe object, perlu dikonversi ke datetime
QI-3	Duplikat	Dicek berdasarkan seluruh baris dan Transaction_ID — hasilnya 0 duplikat
QI-4	Inkonsistensi Season	75% baris Season tidak sesuai dengan bulan pada kolom Date
QI-5	Total_Items Mismatch	Total_Items tidak sesuai dengan jumlah produk aktual di kolom Product
QI-6	Outlier Total_Cost	Ditemukan outlier menggunakan metode IQR pada kolom Total_Cost

QI-7	Format Kolom Product	Kolom Product berupa string representasi list Python, bukan list asli
TI-1	Kolom Product Multivalued	Banyak item dalam 1 sel — perlu di-explode menjadi 1 baris per produk
TI-2	Date Gabung Tanggal+Jam	Kolom Date menggabungkan tanggal dan jam dalam 1 kolom
TI-3	Kolom Season Redundan	Season dapat diturunkan dari Date, 75% tidak konsisten, kolom dihapus

Tabel 2.2 – Ringkasan Quality Issues & Tidiness Issues

2.4 Proses Cleaning Data

- **Fix QI-2:** Konversi kolom Date dari object ke datetime.

```
df_clean['Date'] = pd.to_datetime(df_clean['Date'])
```

- **Fix QI-7 + TI-1:** Parsing kolom Product dari string menjadi list Python menggunakan `ast.literal_eval`, lalu di-explode sehingga setiap produk menjadi 1 baris tersendiri.

```
df_clean['Product'] = df_clean['Product'].apply(parse_product_list)
df_clean = df_clean.explode('Product').reset_index(drop=True)
```

- **Fix QI-1:** NaN pada kolom Promotion diisi dengan label 'No Promotion' saat tahap EDA.

```
df_eda['Promotion'] = df_eda['Promotion'].fillna('No Promotion')
```

- **Lokalisasi & Enrichment:** Mapping produk ke nama Indonesia, Payment_Method, Customer_Category, Discount_Applied ke bahasa Indonesia. Penambahan kolom Estimated_Product_Price_IDR menggunakan price dictionary berbasis harga pasar UMKM.

```
df_real['Estimated_Product_Price_IDR'] = df_real['Product_Name'].map(price_dict)
```

Hasil Cleaning: Dataset bersih disimpan sebagai **retail_cleaned.csv** dengan kolom utama: Datetime, Customer_Name, Product, Estimated_Product_Price_IDR, Payment_Method, Discount_Applied, Customer_Category, Promotion.

BAB 3 – BUSINESS QUESTIONS & EDA

3.1 Definisi Business Questions

Lima pertanyaan bisnis yang dapat diukur dirumuskan sebagai berikut:

#	Business Question	Metrik Ukur
BQ1	Produk apa yang paling sering terjual & nilai penjualan tertinggi?	Frekuensi & total Estimated_Product_Price_IDR per produk
BQ2	Bagaimana tren jumlah transaksi & total nilai belanja per bulan?	Agregasi bulanan (YearMonth) transaksi & total nilai
BQ3	Quarter mana penjualan paling tinggi? Apakah konsisten tiap tahun?	Qty_Sold per Quarter per Year
BQ4	Kategori pelanggan mana paling banyak transaksi & nilai belanja transaksi?	Qty & avg Estimated_Product_Price_IDR per Customer_Category
BQ5	Produk mana berisiko stockout & berapa rekomendasi restock?	Selisih Rekomendasi_Restock vs Qty_Sold + kategori risiko

3.2 Hasil EDA per Business Question

BQ1 – Produk Terlaris & Nilai Penjualan Tertinggi

EDA menampilkan dua visualisasi horizontal bar chart: (1) Top 10 produk paling sering terjual berdasarkan frekuensi, dan (2) Top 10 produk berdasarkan total nilai penjualan (Estimated_Product_Price_IDR). Produk kebutuhan pokok seperti **Beras, Susu, Roti** mendominasi frekuensi, sementara produk premium seperti **Mesin Pemotong Rumput, Penyedot Debu, Setrika** unggul di total nilai penjualan karena harga satuan yang jauh lebih tinggi.

BQ2 – Tren Waktu Bulanan

Line chart ganda menampilkan tren jumlah transaksi dan total nilai belanja per bulan (YearMonth). Pola tren menunjukkan fluktuasi musiman yang konsisten dari tahun ke tahun, dengan puncak transaksi cenderung terjadi di pertengahan dan akhir tahun. Insight ini menjadi dasar pemilihan fitur Quarter dan Is_Peak_Season di Feature Engineering.

BQ3 – Pola Penjualan per Quarter

Bar chart dan line chart per quarter menunjukkan bahwa **Q3 dan Q4 secara konsisten mencatat penjualan tertinggi**, sementara Q2 merupakan titik terendah dengan distribusi paling sempit. Pola ini konsisten di seluruh tahun, yang kemudian divalidasi secara statistik melalui uji ANOVA di BAB 6.

BQ4 – Perilaku Pelanggan

Dua horizontal bar chart dibandingkan: jumlah transaksi vs rata-rata nilai belanja per Customer_Category. Segmen **Ibu Rumah Tangga** mendominasi volume transaksi (kebutuhan pokok rutin), sementara segmen **Profesional** unggul di rata-rata nilai belanja per transaksi. Temuan ini relevan untuk strategi promosi yang lebih tersegmentasi.

BQ5 – Analisis Risiko & Rekomendasi Restock

Bar chart horizontal menampilkan Top 15 produk dengan risiko kehabisan stok tertinggi (warna merah = risiko tinggi, kuning = sedang, hijau = aman), serta pie chart distribusi risiko seluruh produk. Rekomendasi restock dihitung sebagai **1.2x rata-rata penjualan 3 bulan terakhir** per produk, menggunakan logika dari Feature Engineering.

BAB 4 – FEATURE ENGINEERING

4.1 Strategi Feature Engineering

Feature Engineering dilakukan pada dataframe **df_fe** yang merupakan hasil agregasi data per produk per bulan (YearMonth). Seluruh fitur dibangun dari data transaksi historis untuk menangkap pola waktu, tren penjualan, dan kondisi inventaris secara statistik.

4.2 Agregasi Dasar per Produk per Bulan

Sebelum feature engineering, data diagregasi menggunakan groupby:

```
df_fe = df_eda.groupby(['YearMonth', 'Product']).agg(  
Qty_Sold = ('Product', 'count'),  
Total_Sales = ('Estimated_Product_Price_IDR', 'sum'),  
Avg_Sales = ('Estimated_Product_Price_IDR', 'mean'),  
Discount_Rate= ('Discount_Applied', lambda x: (x == 'Ya').mean())  
) .reset_index()
```

4.3 Daftar Fitur yang Dibangun

Fitur	Sumber / Formula	Fungsi dalam Model
Year, Month, Quarter	Ekstraksi dari YearMonth	Menangkap pola waktu dan musiman
Is_Peak_Season	Quarter.isin([3,4]).astype(int)	Flag musim puncak penjualan (Q3 & Q4)
Lag_1, Lag_2, Lag_3	groupby('Product')['Qty_Sold'].shift(n)	Penjualan N bulan sebelumnya per produk
Rolling_Mean_3	shift(1).rolling(3).mean()	Tren rata-rata penjualan 3 bulan terakhir
Rolling_Mean_6	shift(1).rolling(6).mean()	Tren rata-rata penjualan 6 bulan terakhir
Safety_Stock	RM3_Scaled x 0.15 (clip 1-15)	Buffer stok minimum (15% dari rata-rata)
Reorder_Point	RM3_Scaled x 0.5 + Safety_Stock	Titik pemicu restock (maks 60 unit)
Stok_Awal	RM3_Scaled x 1.2 (clip 5-100)	Estimasi stok awal bulan (skala UMKM)
Stok_Akhir	Stok_Awal - Qty_Sold_Scaled	Estimasi sisa stok akhir bulan
Status_Stok	Rule-based: Habis/Perlu Restock/Aman	Kategorisasi kondisi stok real-time
Sales_Growth	pct_change() x 100	Pertumbuhan penjualan bulan ke bulan (%)
Product_Encoded	LabelEncoder() dari sklearn	Encoding nama produk ke integer
Product_Target_Encoded	groupby mean Qty_Sold per produk	Target encoding rata-rata demand produk
Kolom_Scaled (10 fitur)	MinMaxScaler() range 0-1	Normalisasi fitur numerik untuk modeling

Tabel 4.1 – Daftar Lengkap Feature Engineering

4.4 Sistem Inventaris Berbasis Statistik

Inti dari sistem forecasting ini adalah perhitungan **dummy inventory** berbasis skala UMKM (5-100 unit) menggunakan min-max scaling dari Rolling_Mean_3. Pendekatan ini dipilih karena:

- Proporsi antar produk tetap terjaga meskipun volume asli dataset sangat besar.
- Nilai stok disesuaikan ke skala realistis UMKM (bukan skala retail besar).
- Logika safety stock 15% dan reorder point 50% merupakan best practice manajemen inventaris.

4.5 Logika Status Stok

```
def status_stok(row):  
    if pd.isna(row['Reorder_Point']): return 'Data Tidak Cukup'  
    elif row['Stok_Akhir'] <= 0: return 'Habis'  
    elif row['Stok_Akhir'] <= row['Reorder_Point']: return 'Perlu Restock'  
    else: return 'Aman'
```

4.6 Rekomendasi Restock (BQ5)

```
df_restock['Rekomendasi_Restock'] = (df_restock['Avg_3Bulan'] * 1.2).round().astype(int)  
# Buffer 20% di atas rata-rata 3 bulan terakhir
```

Output df_fe akhir: Shape mencakup seluruh kombinasi produk x bulan dengan total lebih dari 20 kolom fitur siap pakai, setelah drop NaN pada Lag_1/2/3 dan Rolling_Mean_3.

BAB 5 – VISUALISASI, DASHBOARD & DEPLOYMENT

5.1 Visualisasi Explanatory Analysis

Seluruh visualisasi dibangun menggunakan **Matplotlib** dan **Seaborn** di Google Colab dengan palette warna konsisten: biru (#85B7EB), hijau (#5DCAA5), oranye (#EF9F27), merah (#E24B4A). Setiap chart disimpan sebagai file PNG (.savefig) dan diintegrasikan ke dashboard Streamlit.

Visualisasi	Tipe Chart	Menjawab
Produk Terlaris & Nilai Penjualan	Horizontal Bar Chart (2 panel)	BQ1
Tren Transaksi & Nilai Belanja Bulanan	Line Chart (dual axis)	BQ2
Pola Penjualan per Quarter	Bar Chart + Line Chart per tahun	BQ3
Perilaku Pelanggan per Kategori	Horizontal Bar Chart (2 panel)	BQ4
Risiko Restock per Produk	Bar Chart + Pie Chart	BQ5
Kualitas Data Assessing	6 panel mixed chart	QC
A/B Testing Test 1	Boxplot (Stok Aman vs Kritis)	Stat
A/B Testing Test 2	Boxplot per Quarter	Stat

5.2 Fitur Dashboard Streamlit

Dashboard interaktif dibangun dengan Streamlit untuk memungkinkan pelaku UMKM mengakses insight tanpa keahlian teknis. Fitur utama yang tersedia:

- **Overview KPI:** Total transaksi, total nilai penjualan, rata-rata nilai belanja.
- **Analisis Produk:** Chart produk terlaris dan nilai penjualan tertinggi (interaktif).
- **Tren Penjualan:** Line chart bulanan nilai belanja dan jumlah transaksi.
- **Pola Seasonal:** Analisis penjualan per quarter yang dapat difilter per tahun.
- **Segmentasi Pelanggan:** Profil perilaku per Customer_Category.
- **Rekomendasi Restock:** Tabel otomatis produk berisiko dengan jumlah restock yang disarankan.
- **Filter Interaktif:** Filter berdasarkan kategori produk, pelanggan, dan periode waktu.
- **Download Data:** Export hasil analisis ke CSV.

5.3 Deployment ke Streamlit Cloud

- Repository GitHub disiapkan dengan struktur folder rapi: app.py, data/, utils/, requirements.txt.
- requirements.txt mencantumkan: streamlit, pandas, numpy, matplotlib, seaborn, scikit-learn, scipy.
- Akun Streamlit Cloud (share.streamlit.io) dihubungkan ke repository GitHub.
- Aplikasi berhasil dideploy dan dapat diakses publik tanpa login.
- Pengujian akhir dilakukan untuk memastikan semua fitur dan chart berjalan di environment production.

BAB 6 – A/B TESTING (VALIDASI STATISTIK)

6.1 Tujuan A/B Testing

A/B Testing dilakukan menggunakan **scipy.stats** untuk memvalidasi secara statistik apakah fitur-fitur yang dibangun di Feature Engineering benar-benar mencerminkan pola penjualan yang nyata dan signifikan, sehingga layak digunakan dalam sistem prediksi.

6.2 Test 1 – Independent T-Test: Status Stok vs Qty Terjual

Hipotesis:

Hipotesis	Pernyataan
H0	Tidak ada perbedaan rata-rata Qty_Sold antara bulan stok aman vs bulan stok kritis
H1	Ada perbedaan rata-rata Qty_Sold antara bulan stok aman vs bulan stok kritis
Metode	Independent T-Test (Welch's) — <code>scipy.stats.ttest_ind(equal_var=False)</code>
Alpha	0.05 (confidence level 95%)

Grup yang Dibandingkan:

- **Grup A (Stok Aman):** Baris `df_fe` dengan `Status_Stok == 'Aman'`
- **Grup B (Stok Kritis):** Baris `df_fe` dengan `Status_Stok == 'Perlu Restock'` atau `'Habis'`

```
grup_aman = df_fe[df_fe['Status_Stok'] == 'Aman']['Qty_Sold']
grup_kritis = df_fe[df_fe['Status_Stok'].isin(['Perlu Restock', 'Habis'])]['Qty_Sold']
t_stat, p_value = stats.ttest_ind(grup_aman, grup_kritis, equal_var=False)
```

Hasil Test 1:

Metrik	Grup A (Aman)	Grup B (Kritis)
n Sampel	366 baris	3.684 baris
Rata-rata Qty_Sold	585 unit	709 unit
T-Statistic	-24.55	—
P-Value	0.000000 (< 0.05)	—
Kesimpulan	TOLAK H0	Perbedaan SIGNIFIKAN

Interpretasi Test 1: Stok kritis terjadi justru saat demand TINGGI (rata-rata 709 unit vs 585 unit saat aman). Dari boxplot terlihat outlier ekstrem di atas 1.400 unit pada stok kritis, menunjukkan lonjakan permintaan mendadak. Ini membuktikan fitur `Status_Stok` dan `Discount_Rate` PENTING dan valid untuk dimasukkan ke sistem prediksi.

6.3 Test 2 – One-Way ANOVA: Quarter vs Qty Terjual

Hipotesis:

Hipotesis	Pernyataan
H0	Rata-rata Qty_Sold sama di semua quarter (Q1 = Q2 = Q3 = Q4)
H1	Minimal satu quarter memiliki rata-rata Qty_Sold yang berbeda
Metode	One-Way ANOVA — <code>scipy.stats.f_oneway(q1, q2, q3, q4)</code>
Alpha	0.05 (confidence level 95%)

```
q1 = df_fe[df_fe['Quarter'] == 1]['Qty_Sold'] # dst untuk Q2, Q3, Q4
f_stat, p_anova = stats.f_oneway(q1, q2, q3, q4)
```

Hasil Test 2:

Quarter	Rata-rata Qty_Sold	n Sampel
Q1	698 unit	~1.000 baris
Q2	680 unit	~1.000 baris
Q3	708 unit	~1.000 baris
Q4	710 unit	~1.000 baris
F-Statistic	24.60	—
P-Value	0.000000 (< 0.05)	—
Kesimpulan	TOLAK H0	Perbedaan SIGNIFIKAN antar quarter

Interpretasi Test 2: Q4 adalah puncak penjualan (710 unit) dan Q2 adalah titik terendah (680 unit) dengan outlier ekstrem di bawah 400 unit. Pola musiman ini konsisten dan terbukti signifikan secara statistik — membuktikan fitur Quarter dan `Is_Peak_Season` valid dan PENTING untuk dimasukkan ke sistem prediksi demand.

BAB 7 – HASIL AKHIR & KESIMPULAN

7.1 Ringkasan Deliverable Capstone

#	Deliverable	Status	Detail
1	Problem Discovery & Pain Point	SELESAI	5 pain point UMKM teridentifikasi
2	Pengumpulan Data (Gathering)	SELESAI	CSV dari Google Drive via Colab
3	Assessing Data	SELESAI	7 QI + 3 TI teridentifikasi & divisualisasi
4	Cleaning Data	SELESAI	Explode Product, konversi datetime, mapping IDR
5	Definisi Business Questions terukur	SELESAI	5 BQ dengan metrik evaluasi jelas
6	Exploratory Data Analysis (EDA)	SELESAI	5 BQ dijawab dengan visualisasi Matplotlib
7	Visualisasi & Explanatory Analysis	SELESAI	8 chart interaktif + penjelasan insight
8	Feature Engineering	SELESAI	15+ fitur: Lag, Rolling, Safety Stock, Scaling
9	Data Dictionary	SELESAI	13 kolom terdokumentasi lengkap
10	Dashboard Streamlit interaktif	SELESAI	8 fitur + deployment publik Streamlit Cloud
11	A/B Testing dengan Python (scipy.stats)	SELESAI	T-Test & ANOVA: keduanya $p < 0.05$
12	Laporan Teknis PDF Komprehensif	SELESAI	Dokumen ini (sesuai codingan asli)

7.2 Kesimpulan

Proyek **Smart Inventory Forecasting** berhasil membuktikan bahwa pendekatan statistical forecasting berbasis data historis dapat memberikan nilai nyata bagi UMKM dalam mengelola inventaris secara lebih cerdas.

Sistem menggunakan **Rolling Mean (3 & 6 bulan)** dan **Lag Features** sebagai basis prediksi demand, dilengkapi dengan perhitungan **Safety Stock** (buffer 15%), **Reorder Point**, dan **Rekomendasi Restock** (1.2x rata-rata 3 bulan) yang disesuaikan ke skala realistis UMKM.

Validasi statistik melalui **Independent T-Test** ($p=0.000000$, $T=-24.55$) dan **One-Way ANOVA** ($p=0.000000$, $F=24.60$) membuktikan bahwa fitur-fitur yang dibangun benar-benar mencerminkan pola penjualan yang nyata dan signifikan.

Dashboard Streamlit yang telah dideploy memungkinkan pelaku UMKM mengakses insight berbasis data tanpa keahlian teknis — menjembatani teknologi dan kebutuhan praktis bisnis.

Kesimpulan Utama: Sistem ini adalah PAINKILLER sejati — bukan sekadar mencatat stok, tetapi secara aktif MENCEGAH kerugian finansial UMKM akibat deadstock dan stockout melalui peramalan berbasis data dan rekomendasi restock yang terukur.

7.3 Rekomendasi Pengembangan

- Integrasi model Machine Learning (Random Forest / XGBoost) di atas fitur yang sudah dibangun untuk meningkatkan akurasi prediksi.

- Integrasi real-time data melalui POS (Point of Sale) UMKM untuk update stok otomatis.
- Penambahan fitur notifikasi otomatis (WhatsApp Business API) saat stok mendekati Reorder Point.
- Pengembangan model SARIMA untuk forecasting jangka panjang dengan komponen musiman yang lebih kuat.
- Ekspansi dataset ke konteks UMKM Indonesia (data transaksi warung, toko kelontong, minimarket lokal).